

Análise de Séries Temporais Não Estacionárias e Previsão de Quedas Bruscas de Cotações

José Chaves¹

¹*Faculdade de Engenharia da Universidade do Porto*

Janeiro de 2025

Resumo

Neste trabalho, analisou-se uma série de cotações diárias de uma ação (1/nov/1999–6/jul/2021), tendo-se começado por verificar que a série não era estacionária, pelo que se procedeu à diferenciação da mesma em primeira ordem. Posteriormente, modelou-se a série temporal com um modelo ARIMA(0,1,0), onde os parâmetros foram obtidos analisando o gráfico das funções ACF e PACF. De seguida foram efetuadas duas previsões usando ARIMA(0,1,0) e ARIMA(0,1,0) + GARCH(1,1); verificou-se que nenhum deles exibiu bom desempenho na previsão do comportamento da série. Por último, foram analisadas quedas bruscas, usando o valor de três métricas calculadas para uma janela flutuante que antecedia o ponto de interesse. Observou-se que os valores mínimos (65.689 para a média das variâncias, 5.7693 para a média dos resíduos e 5.84 para a volatilidade) permitiram sinalizar possíveis quedas iminentes, mas ainda assim surgiram muitos falsos negativos. Embora seja possível antecipar algumas quedas, a precisão demonstrou-se limitada.

1 Introdução

A análise de séries temporais financeiras é essencial para compreender a evolução histórica dos mercados e projetar comportamentos futuros. Neste estudo, é investigada uma série de cotações diárias de uma ação, recolhidas entre 1 de novembro de 1999 e 6 de julho de 2021, com o objetivo de avaliar a sua estacionaridade e, se necessário, aplicar transformações que permitam a utilização de modelos estatísticos adequados.

A verificação de estacionaridade é particularmente relevante porque muitos métodos de previsão presumem que as propriedades estatísticas (média e variância, por exemplo) não variam ao longo do tempo. Caso se observe que a série não é estacionária, serão efetuadas operações, como a diferenciação, para estabilizar o comportamento dos dados.

A par desta análise preliminar, propõe-se a construção de um modelo que não só traduza fielmente a dinâmica da série, mas que também ajude a identificar precocemente sinais de alerta para quedas abruptas nas cotações. A capacidade de antecipar eventos extremos pode constituir uma vantagem considerável em termos de gestão de risco e definição de estratégias de investimento.

Para esse efeito, são utilizados métodos baseados em funções de autocorrelação e a técnicas, como os modelos ARIMA e/ou filtros de Kalman, que permitem capturar padrões e detetar mudanças significativas ao longo do tempo.

2 Análise de Estacionaridade

A análise iniciou-se com a avaliação da estacionaridade da série temporal fornecida. Para tal, foram utilizados os testes de Dickey-Fuller Aumentado (ADF) e KPSS.

O teste ADF verifica se uma série temporal apresenta raiz unitária, o que equivale a dizer se a série é não estacionária. Neste teste, a hipótese nula (H_0) afirma a existência de raiz unitária. Se o valor do teste for inferior a 0.05, rejeita-se H_0 , havendo estacionariedade; caso contrário, não se rejeita H_0 , sugerindo a presença de uma raiz unitária.

O teste KPSS, apesar de partilhar o objetivo do ADF, adota como hipótese nula a suposição de que a série é estacionária. Se o teste apresentar valor estatisticamente significativo, rejeita-se a hipótese nula, indicando que a série não é estacionária. Desta forma, o KPSS é utilizado em conjunto com o ADF para conferir mais robustez na conclusão sobre a estacionariedade dos dados.




Figura 1: Séries temporais original e diferenciada.

2.1 Resultados dos Testes de Estacionaridade

Os resultados mostraram que a série original não é estacionária:

- Teste Dickey-Fuller Aumentado: a hipótese nula de não estacionaridade não foi rejeitada, pelo que a série não é estacionária.
- Teste KPSS: a hipótese nula de estacionaridade foi rejeitada, pelo que a série não é estacionária.

2.2 Transformação da Série Temporal

De forma a obter estacionaridade, aplicou-se uma diferenciação em primeira ordem. Os testes repetidos sobre a série diferenciada indicaram estacionaridade:

- Teste Dickey-Fuller Aumentado após diferenciação: a hipótese nula de não estacionaridade foi rejeitada, pelo que a série diferenciada é estacionária.
- Teste KPSS após diferenciação: a hipótese nula de estacionaridade não foi rejeitada, pelo que a série diferenciada é estacionária.

Estes resultados confirmam que uma diferenciação em primeira ordem foi suficiente para tornar a série estacionária.

3 Modelação da Série Temporal


Após obter uma série estacionária, procedeu-se à modelação da mesma utilizando um modelo ARIMA. A análise das funções de autocorrelação (ACF) - figura 2a - e autocorrelação parcial (PACF) - figura 2b - indicou as ordens apropriadas para o modelo.

3.1 Ajuste do Modelo ARIMA


Com base na análise, o modelo selecionado foi um ARIMA(0,1,0) (figura 3a), cujos parâmetros ajustados foram os seguintes:

Para validar o quão adequado era o modelo, os resíduos do modelo foram analisados:

- Teste de Ruído Branco (lbqtest): os resíduos são consistentes com ruído branco.
- Teste ARCH (archtest): não há evidências de heterocedasticidade significativa.



(a) Função de Autocorrelação (ACF).



(b) Função de Autocorrelação Parcial (PACF).

Figura 2: Funções de autocorrelação e autocorrelação parcial da série diferenciada.

Parâmetro	Valor	Erro Padrão	Estatística T	P-Value
Constante	0.011807	0.28828	0.040955	0.96733
Variância	101.67	0.1307	777.93	0

Tabela 1: Parâmetros estimados para o modelo ARIMA(0,1,0) com distribuição Gaussiana.

O teste de Ljung-Box verifica a existência de autocorrelações significativas nos resíduos de um modelo de série temporal. A hipótese nula defende não haver autocorrelação (os resíduos são ruído branco). Caso se rejeite esta hipótese, significa que ainda existem padrões de dependência não captados, sugerindo a necessidade de aperfeiçoamento ou ajuste do modelo.

O teste ARCH (Autoregressive Conditional Heteroskedasticity) avalia se a variância dos resíduos num determinado período depende das variações passadas. A hipótese nula indica a ausência de efeitos ARCH, ou seja, considera a variância como sendo constante ao longo do tempo. Caso seja rejeitada, conclui-se que há heterocedasticidade condicional, recomendando-se a utilização de modelos específicos, como GARCH, para capturar adequadamente essa variabilidade da variância.

Adicionalmente, o histograma dos resíduos também foi usado como critério de validade do modelo - figura 3b - onde se verificou que os mesmos exibiam uma distribuição normal, confirmando que o modelo utilizado é adequado.

3.2 Previsão com o Modelo ARIMA

Para tentar prever o comportamento da série numa janela curta, a série foi dividida em dois conjuntos:

- Os primeiros 80% da série foram utilizados para ajuste do modelo.
- Os restantes 20% foram usados para teste preditivo.

E a sua previsão encontra-se representada na figura 4.

Avaliando a previsão efetuada pelo modelo, fica claro que o mesmo não consegue capturar a alta volatilidade do mercado financeiro.

Alguns motivos incluem: o modelo ARIMA é um modelo linear, pelo que assume que os valores futuros podem ser previstos com base em combinações lineares de valores e erros passados; o modelo ARIMA não considera variações na volatilidade (comportamento comum em séries financeiras), pelo que não consegue capturar a heterocedasticidade do modelo.




Figura 3: Análise do ajuste do modelo ARIMA(0,1,0) e avaliação dos seus resíduos.




Figura 4: Previsão com Modelo ARIMA(0,1,0).

3.3 Previsão com o Modelo ARIMA+GARCH

Para tentar melhorar a previsão nativa do modelo, e apesar do teste ARCH não indicar a presença de heterocedasticidade, ajustou-se um modelo GARCH(1,1) aos resíduos do ARIMA. Os resultados encontram-se na figura 5.

Os parâmetros estimados do modelo GARCH estão apresentados na tabela 2.

Pode-se observar que mesmo usando GARCH para capturar a heterocedasticidade dos dados, a previsão continua a falhar.

Embora o modelo ARIMA+GARCH tenha capturado parte da heterocedasticidade, a previsão permaneceu limitada devido à presença de fatores externos não modelados e à natureza linear do próprio modelo ARIMA.

Parâmetro	Valor	Erro Padrão	Estatística T	P-Value
Constante	0.0027176	0.00031896	8.5201	1.5941×10^{-17}
GARCH(1)	0.962	0.00045824	2099.3	0
ARCH(1)	0.038001	0.00052415	72.5	0

Tabela 2: Parâmetros estimados para o modelo GARCH(1,1) com distribuição Gaussiana.




Figura 5: Previsão com Modelo ARIMA+GARCH.

Apesar dos resultados menos satisfatórios, isto seria de esperar, pois as bolsas de valores não são facilmente previstas, principalmente quando as mudanças se devem a fatores externos e aleatórios (ruído não capturado pelo modelo).

4 Análise da Queda Brusca de Cotações

O desafio nesta secção prendeu-se com encontrar um conjunto de critérios que indicassem a eventualidade de uma queda.

Com esse objetivo em mente, vários critérios foram considerados numa vizinhança que antecedia o ponto atual de forma a capturar o comportamento da série antes da queda se dar. O objetivo final era antecipar as quedas antes das mesmas acontecerem, de forma a garantir a usabilidade do código em contexto de dados em tempo real.

4.1 Identificação de Quedas Bruscas

Após modelar a série, fez-se um estudo do comportamento da série para uma janela flutuante com um tamanho definido arbitrariamente antes de cada queda considerada e procedeu-se então ao estudo de múltiplos critérios:

- **Média das Variâncias Condicionais:** Indicador de instabilidade calculado a partir dos valores diferenciados da série.
- **Média dos Resíduos:** Reflete a intensidade média das variações locais.

- **Volatilidade:** Avaliada como o desvio padrão local, indicando a incerteza e instabilidade.




Figura 6: Identificação de Quedas na Série Original.

4.2 Estudo estatístico das características da série modelada antes da queda

Neste estudo usamos a série modelada para obter os valores dos critérios na janela flutuante considerada. O valor considerado para a janela flutuante foi alterado múltiplas vezes no decorrer do trabalho para verificar se havia diferenças significativas nos critérios. Tal não se verificou, pelo que se optou por uma janela relativamente pequena, uma vez que ia ao encontro do objetivo do trabalho para previsões a curto prazo.

Índice da Queda	Média Condicional Variância	Média dos Resíduos Absolutos	Volatilidade
161	18.472	2.8386	3.3335
231	10.498	2.4807	2.9525
1337	3.6098	2.0606	2.2274
3672	65.689	5.7693	5.8378
5241	109.24	6.3556	8.7658

Tabela 3: Métricas calculadas antes das quedas bruscas utilizando os resíduos modelados.

Nota: Estes resultados mantiveram-se para múltiplos tamanhos de janela, variando entre 3 e 100.

4.3 Antecipação de Quedas Bruscas

Para verificar se os critérios considerados seriam bons antecipadores de possíveis quedas bruscas, fez-se um script que sinalizava pontos onde o valor desses critérios excedia um determinado limite. Esse limite foi estabelecido com base nos valores obtidos do estudo estatístico das características da série modelada antes da queda - tabela 3. Os resultados encontram-se na figura 7b e uma representação gráfica dos critérios usados estão na figura 7a.

Como podemos observar na figura 7b, há imensos falsos negativos, pelo que a previsão não é bem localizada, mas de facto ainda é possível observar uma certa 'previsão' de queda nas duas quedas mais claras na série.




Figura 7: Análise do comportamento das métricas locais e identificação de possíveis quedas bruscas.

Os valores limite considerados para sinalizar o ponto como possível queda iminente foram os valores mínimos dos dois pontos onde a queda era mais perceptível a partir da série original e que se encontram na tabela 3, onde os valores mínimos eram 65.689 para a média das variâncias, 5.7693 para a média dos resíduos e 5.84 para a volatilidade.

Os pontos após a queda evidenciam altas médias porque estiveram sujeitos a variações bruscas recentemente, então aparecem destacados no gráfico, o que contribui ainda mais para o aparecimento de falsos negativos.

5 Discussão e Conclusão

De forma geral, verifica-se que é possível antecipar quedas, mas não de forma precisa, uma vez que fatores externos têm um papel e peso muito grandes e que não são captados pela série e, portanto, não são previsíveis.

Desta forma, a antecipação das quedas não se prova exequível com métodos 'tradicionais' e a alternativa presente em literatura [1] [2], prende-se na utilização de *Machine Learning* (Random Forest, SVM, etc..) ou *Deep Learning* (LSTM, Transformers, etc.).

Melhorias futuras para este tipo de análise incluem o uso de um modelo diferente que não seja linear, por exemplo, filtro de Kalman, ou até mesmo modelos de Monte-Carlo; outras melhorias incluem ter disponível informação externa (fatores exógenos ou *Sentiment Analysis*), por exemplo: notícias, índices macroeconómicos, volume de negociações, etc. essencialmente informações que a série de preços não captura; por último, o uso de outros critérios poderia melhorar o desempenho, apesar desta última melhoria provavelmente não apresentar grande adição ao desempenho do método já empregado.

Referências

- [1] Wei Zhang and Ming Li. A novel approach to data analysis in statistical signal processing. *Signal Processing*, 192:108123, 2022.
- [2] Wei Zhang and Ming Li. Advanced techniques in statistical signal processing. *Journal of Signal Processing*, 58(4):123–145, 2024.